KG 구축 K1 추출 단위 나누기

LLM에 한 번에 넣는 글 조각을 뜻 단위(조항)로 맞춤. 검색용 청크는 그대로 두고 추출 직전에만 나눔

왜 나누나

청크 그대로	**약관 청크 1개** 1,449자, 조항 9개	**LLM 1번** →	**조항, 문서 노드만** 조항 안 내용은 놓침
조항 단위	**조항 9개로 나눔** 제16조 ~ 제21조	**LLM 9번** →	**조건, 기한, 처리** 노드가 나오기 시작

약관 스키마 실험 결과. 조항 단위도 합격 기준은 아직 못 넘어 스키마 설명을 다듬는 중

어떻게 나누나 (약관)

1. 조항 제목 줄 찾기: 「제16조(할부 거래)」 꼴
2. 다음 줄이 ①로 시작할 때만 시작점 (차례 줄은 건너뜀)
3. 다음 제목 전까지가 한 단위 (장 제목 줄은 버림)
4. **겹친 조항은 하나로 합치고 부모 청크 ID는 모두 기록**

문서 종류별 추출 단위

문서 종류	추출 단위	청크 → 단위
약관	조항 제목 줄로 나눔	10 → 51
혜택 안내	청크 그대로 (카드 경계로 이미 나뉨)	160 → 160
상담 기록	청크 그대로 (상담 1건)	48 → 48

약관 단위 길이 97 ~ 632자(중앙 147자). 차례뿐인 청크는 단위가 0개

검색 청크와 잇기

검색엔진이 찾은 chunk_id → **추출 단위 노드** parent_chunk_ids에 있음 → **질문에 필요한** 근거 노드

규칙은 스키마 승인 기록에서 가져옴.
스키마 설계, 시험, 인덱싱이 모두 같은 단위를 씀

무단전재 및 배포 금지

K1 추출 단위 나누기 코드

제목 줄과 본문 시작 표시로 조항을 자르고, 겹친 조항은 합치면서 부모 청크 ID를 모음

나누기 규칙과 _split_by_heading (tools/common.py 발췌)

```
RULE = {"heading": r"^(제\d+조(?:의\d+)?)\(([^)]*)\)\s*$",  # 조항 제목 줄
        "body_start": "①",                  # 본문 시작 표시
        "drop_lines": r"^제\d+장\s"}         # 버릴 줄(장 제목)

def _split_by_heading(chunk, rule):
    heading = re.compile(rule["heading"])
    drop = re.compile(rule["drop_lines"])
    lines = chunk["text"].split("\n")
    nxt = lambda i: next((l.strip() for l in lines[i + 1:] if l.strip()), "")
    # 제목 줄이면서 다음 줄이 ①로 시작하는 줄만 시작점(차례 제외)
    starts = [i for i, l in enumerate(lines) if heading.match(l.strip())
              and nxt(i).startswith(rule["body_start"])]
    units = []
    for k, i in enumerate(starts):
        end = starts[k + 1] if k + 1 < len(starts) else len(lines)
        body = [l for l in lines[i:end] if not drop.match(l.strip())]
        m = heading.match(lines[i].strip())
        units.append({"id": f"{chunk['doc_type']}:{m.group(1)}",  # regulation:제16조
                      "text": "\n".join(body).strip(),
                      "parent_chunk_ids": [chunk["id"]]})
    return units
```

split_chunks: 겹친 조항 합치기

```
def split_chunks(chunks, rule):
    merged = {}
    for c in chunks:
        for u in _split_by_heading(c, rule):
            old = merged.get(u["id"])
            if old is None:
                merged[u["id"]] = u
                continue
            # 같은 조항이 또 나오면 긴 글 + 부모 ID 모음
            parents = (old["parent_chunk_ids"]
                       + u["parent_chunk_ids"])
            keep = u if len(u["text"]) > len(old["text"]) else old
            merged[u["id"]] = {**keep, "parent_chunk_ids": parents}
    return list(merged.values())
```

결과 예 (약관 청크 10개 → 단위 51개)

```
{"id": "regulation:제16조의2",
 "text": "제16조의2(할부 거래의 철회 요청)\n① ...",
 "parent_chunk_ids": ["D1_..._112f1e4abea05436_0000",
                      "D1_..._a4fd4ae81ec3f063_0000"]}
```

부모 청크 2개인 단위 13개: 어느 청크가 검색돼도 이 조항으로 이어짐

무단전재 및 배포 금지