K5 병합의 원리

스키마 설계에서 정한 고유 속성 제약을 K4가 노드와 맞춰 보고 값을 모으면, K5가 그 값으로 같은 세대의 노드를 찾아 합침

① 스키마 설계 (정함)

schema_spec.json에 정하고 graph_schema.json으로 확정

```
{"type": "UNIQUENESS",
 "node_type": "TermsDocument",
 "property_name": "version"}
```

→

② 인덱싱 준비 (읽음)

load_schemas()가 문서 유형별 graph_schema.json을 읽음

```
약관: TermsDocument.version
혜택: ProductGuide.product_id
상담: Consultation.record_id
```

→

③ K4 적재 (모음)

노드 라벨이 제약 라벨과 같고 값이 있으면 (라벨, 속성, 값)을 모음

```
merge_keys = {
  ("TermsDocument",
   "version", "1.2")}
```

→

④ K5 병합 (합침)

값마다 같은 세대에서 값이 같은 노드를 찾아 2개 이상이면 mergeNodes

```
TermsDocument 1.2
16개 → 1개
```

③의 비교: 약관 제16조 단위에서 뽑힌 노드 (제약의 node_type은 'TermsDocument')

n.label	c.node_type == n.label	결과
TermsDocument	**참**	**모음 (version 1.2)**
Clause	거짓	건너뜀
Requirement	거짓	건너뜀
Handling	거짓	건너뜀

조항 16개 단위가 같은 키를 넣어도 set이라 키는 1개만 남음

제약을 쓰는 곳과 안 쓰는 곳

K2 추출	LLM에 보이지만 단위끼리 서로 몰라 중복이 생김
K3 가지치기	필수 속성만 보고 고유 속성은 안 봄
Neo4j	제약을 걸지 않음. 걸면 K4 쓰기가 실패함
K4와 K5	**실제로 쓰는 곳: 값을 모으고 합침**

무단전재 및 배포 금지

KG 구축 K5 병합

노드를 합칠 때 사용 하는 스키마의 고유 속성 값이 같은 노드를 하나로 합쳐, 여러 추출 단위에 흩어진 같은 대상을 한 노드로 모음

합치는 기준: 스키마의 고유 속성

약관
TermsDocument.version

혜택 안내
ProductGuide.product_id

상담 기록
Consultation.record_id

고유 속성이 없는 라벨은 합치지 않음
Clause, Proposal 등

예 1. 약관 문서 노드 (조항 16개에서 각각 뽑힘)

TermsDocument 1.2 → Clause (조항 1)
TermsDocument 1.2 → Clause (조항 2)
TermsDocument 1.2 → Clause (조항 3)

... 16쌍 (약관 문서 노드도 16개)

mergeNodes →

TermsDocument
1.2 (하나)

→ Clause (조항 1)
→ Clause (조항 2)
→ Clause (조항 3)

... HAS_CLAUSE 16개, FROM_CHUNK 16개

예 2. 상담 노드 (앞 상담 참조와 본문)

Consultation C-20260302-002
record_id만 (다른 상담의 FOLLOWS로 생김)

Consultation C-20260302-002
속성 5개 (그 상담 본문에서 뽑힘)

mergeNodes →

Consultation C-20260302-002
속성 5개 (빈 속성이 채워짐)
FOLLOWS 1, FROM_CHUNK 2 유지

1 이번에 들어온 값만

K4가 모은 값만 검사. 관련 엔티티만 건드림

2 같은 세대 안에서만

generation이 같은 노드끼리 합침

무단전재 및 배포 금지

K5 병합 코드 (kg_build.py)

K4에서 모은 (라벨, 속성, 값)마다 같은 세대의 노드를 찾아, 2개 이상이면 APOC로 하나로 합침

합칠 값 모으기(apply)와 k5_merge (kg_build.py 발췌)

```
# apply() 안(K4): 합칠 값 모으기. 이번에 쓴 노드만
for c in schemas[u["doc_type"]]["schema"].constraints:
    if (c.node_type == n.label
            and n.properties.get(c.property_name) not in (None, "")):
        merge_keys.add((n.label, c.property_name,
                        str(n.properties[c.property_name])))

def k5_merge(driver, generation, keys):
    groups = 0
    for label, prop, value in sorted(keys):
        records, _, _ = driver.execute_query(
            f"MATCH (n:`{label}` {{generation: $g}}) "
            f"WHERE toString(n.`{prop}`) = $v "
            "WITH collect(n) AS ns WHERE size(ns) > 1 "
            "CALL apoc.refactor.mergeNodes(ns, "
            "{properties: 'discard', mergeRels: true}) "
            "YIELD node RETURN count(node) AS c",
            g=generation, v=value)
        groups += sum(r["c"] for r in records)
    return groups
```

v0 표본에서 합쳐진 묶음 (전체 재색인)

라벨	고유 속성 값	전 → 뒤
TermsDocument	version 1.2	16 → 1
ProductGuide	product_id D2-C021	4 → 1
Consultation	record_id C-20260302-002	2 → 1

합쳐진 약관 문서 노드 (Neo4j 조회)

(:TermsDocument {version: "1.2",
effective_date: "2027-01-15", supersedes: "1.1"})
-[:HAS_CLAUSE]→ 조항 노드 16개
-[:FROM_CHUNK]→ 추출 단위 노드 16개

v0 표본 결과

전체 재색인: 3묶음, 엔티티 110 → 91
증분 색인: 3묶음, 새 엔티티 29개 중 5개가 기존 노드와 합쳐짐

무단전재 및 배포 금지