2. 인덱싱: KG 구축 – K8. 커뮤니티 요약 (선택)

서로 촘촘히 이어진 엔티티를 Leiden으로 묶고, 묶음마다 LLM이 요약 보고서를 써서 거시 질문에 답할 재료를 만듦

사실 질문: 엔티티 하나로 답함
「할부로 산 물건은 며칠 안에 철회하나요?」
→ 기한 엔티티 「7일 이내 철회」

거시 질문: 여러 문서를 훑어 묶어야 답함
「고객군별로 고객 불만을 주제별로 나눠 주세요」
→ 미리 만들어 둔 커뮤니티 보고서로 답함 (K8)

① 그래프 읽기	② Leiden 묶기	③ 보고서 쓰기	④ 임베딩	⑤ 적재
엔티티와 관계만 청크 노드는 뺌	**GDS가 촘촘한** 묶음을 찾음	**LLM이 제목, 요약,** 핵심 사실을 씀	**보고서를 KURE-v2로** 벡터로 바꿈	**Community 노드와** IN_COMMUNITY 관계

1 엔티티만 묶음
청크 노드를 넣으면 청크 단위로만 뭉침

2 3개 이상만 요약
엔티티 1 ~ 2개 묶음은 보고서를 쓰지 않음

3 같으면 재사용
구성원 지문이 같으면 LLM을 부르지 않음

4 실행 위치
전체 재색인은 K6 다음, 증분 색인은 K7 다음

선택 단계: 실행할 때 --communities 옵션으로 켬
Microsoft GraphRAG의 커뮤니티 보고서와 같은 생각. 거시 질문이 없으면 꺼 둠

무단전재 및 배포 금지

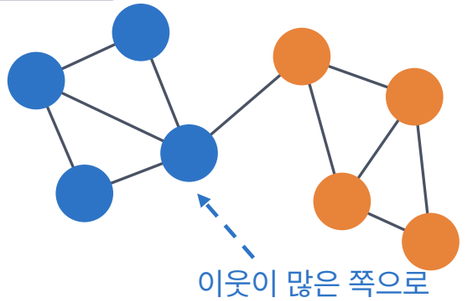
2. 인덱싱: KG 구축 – K8. Leiden으로 커뮤니티 찾기 (원리)

묶음 안 연결은 많고 묶음 사이 연결은 적게 나누는 것이 목표. 옮기기, 다듬기, 합치기를 점수가 더 오르지 않을 때까지 반복

좋은 나누기의 기준: 모듈성

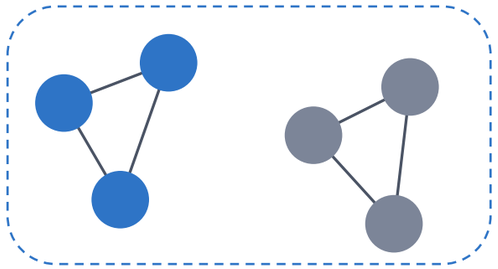
묶음 안 연결이 우연히 이어질 때보다 얼마나 더 많은가. 묶음 안은 촘촘하고 묶음 사이는 성길수록 높음

① 옮기기



점 하나씩 이웃 묶음으로 옮겨 보고, 점수가 오르면 옮김

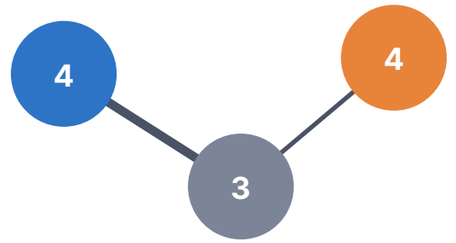
② 다듬기



점선: ①에서 정한 한 묶음. 안이 끊어져 회색 조각을 따로 묶음

묶음 안에서 끊어진 조각은 떼어 냄 (Louvain에 없던 단계)

③ 합치기



점 안 숫자: 합쳐진 엔티티 수, 선 굵기: 묶음 사이 연결 수

묶음을 점 하나로 보고 ①부터 다시. 점수가 그대로면 끝

같은 그래프면 늘 같은 묶음

옮겨 보는 순서에 따라 결과가 달라질 수 있어 씨앗(randomSeed)을 고정하고 병렬 처리를 하나로 둠

무단전재 및 배포 금지

2. 인덱싱: KG 구축 – K8. GDS로 커뮤니티 찾기 (코드)

Neo4j 안에서 엔티티 그래프를 메모리에 투영하고, gds.leiden.stream으로 묶음 번호를 받은 뒤 투영을 지움

detect (community.py 발췌)

```
# ① 투영: 엔티티를 키 순서로 넣고 엔티티 사이 관계만 이음(청크 노드는 없음)
driver.execute_query(
    "UNWIND $rows AS row MATCH (s) WHERE elementId(s) = $ids[row.s] "
    "OPTIONAL MATCH (t) WHERE row.t IS NOT NULL AND elementId(t) = $ids[row.t] "
    "WITH gds.graph.project($name, s, t, {}, "
    "{undirectedRelationshipTypes: ['*']}) AS g "
    "RETURN g.nodeCount AS n", rows=rows, ids=ids, name=name)
# ② Leiden: 씨앗 고정, 병렬 1 → 같은 그래프면 같은 묶음
records, _, _ = driver.execute_query(
    "CALL gds.leiden.stream($name, {randomSeed: $seed, concurrency: 1}) "
    "YIELD nodeId, communityId "
    "RETURN elementId(gds.util.asNode(nodeId)) AS id, communityId AS c",
    name=name, seed=config.COMMUNITY_SEED)
# ③ 투영 그래프는 메모리에만 있으므로 끝나면 반드시 지움
driver.execute_query("CALL gds.graph.drop($name, false) YIELD graphName " ...)
```

투영 그래프
필요한 노드와 관계만 메모리에 복사한 그래프. GDS 알고리즘은 이 위에서 돎

무방향
관계 방향은 묶음과 상관없어 양쪽으로 봄

stream 방식
그래프를 고치지 않고 엔티티마다 묶음 번호만 돌려줌

Community Edition
GDS도 무료. 모든 알고리즘을 쓰고 병렬은 4코어까지

v0 전체 재색인: 엔티티 1,663개, 관계 1,527개 → 묶음 144개
엔티티 3개 이상 78개 요약. 가장 큰 묶음 147, 37, 32개. 문서 종류가 섞인 묶음 0개

무단전재 및 배포 금지

2. 인덱싱: KG 구축 – K8. 묶음마다 보고서 쓰기 (원리와 코드)

묶음의 엔티티 설명과 관계를 LLM에 주고, 근거 엔티티를 단 제목, 요약, 핵심 사실을 받아 임베딩해 저장함

LLM 입력과 출력 (프롬프트 요지)

엔티티:
e1. Complaint: cause=매달 계산도 부담이고요.
e2. Complaint: cause=실적을 매번 챙기는 것도 부담이에요.
관계:
e9 -[HAS_COMPLAINT]→ e1

출력(JSON): {"title": "묶음 주제 한 줄", "summary": "3 ~ 5문장",
"findings": [{"text": "핵심 사실", "entities": ["e1"]}]}

⑤ 적재 (community.py 발췌)

```
CREATE (c:Community {community_id, title, summary,
  findings, member_hash, size, generation, run_id})
CALL db.create.setNodeVectorProperty(c, 'embedding', row.vec)
CREATE (e)-[:IN_COMMUNITY]→(c)      // 묶음의 엔티티마다
CREATE VECTOR INDEX kg_community_embedding ...
```

실제 보고서 예 (v0 전체 재색인, 엔티티 23개 묶음)

연회비 대비 가치에 대한 고객 불만 및 상담 흐름
고객은 연회비에 비해 실질적인 혜택이 부족하다고 불만을 제기하고, 매달 계산과 실적 관리까지 부담을 느낍니다. 이와 관련해 앱 채팅, 영업점 방문, 콜센터 통화를 통해 연회비 대비 가치를 평가하는 상담이 연속적으로 진행되었습니다. 상담 과정에서 결제 수단 변경, 연회비 분납, 비용 확인 등 다양한 제안이 제시되었으며, 일부는 수용되고 일부는 보류·거절되었습니다. 고객은 다음 청구서를 확인한 뒤 최종 결정을 내리겠다고 밝혔습니다.

핵심 사실과 근거 엔티티

고객은 연회비가 높지만 체감 혜택이 없어 생활비 관리에 부담을 느낀다. [근거: Complaint(연회비 하나 때문에 생활비 관리 방식을 전부 바꾸고 싶지는 않아요.), Complaint(연회비는 그대로인데 제가 받는 혜택이 없다는 게 불만이에요.) ...]

월별 계산과 실적 추적 요구가 추가적인 스트레스를 유발한다. [근거: Complaint(매달 계산도 부담이고요.), Complaint(실적을 매번 챙기는 것도 부담이에요.) ...]

앱 채팅, 영업점, 콜센터 등 여러 채널에서 연회비 대비 가치에 대한 상담이 연속적으로 이루어졌다. [근거: Consultation(앱 채팅), Consultation(영업점) ...]

1 근거를 단다
핵심 사실마다 근거 엔티티를 적어 지어낸 내용을 되짚음

2 지문으로 재사용
보고서 판, 구성원, 관계가 같으면 LLM을 부르지 않음

3 엔티티가 아님
Community 노드에는 엔티티 라벨을 붙이지 않음

무단전재 및 배포 금지

2. 인덱싱: KG 구축 – K8. 커뮤니티 보고서로 거시 검색하기

질문과 가까운 보고서를 벡터로 찾고, 그 보고서들만 근거로 LLM이 답을 씀 (Microsoft GraphRAG의 Global Search 방식)

질문 예: 「고객군별로 고객들이 말한 불만을 주제별로 나눠 주세요」

① 질문 임베딩	② 보고서 찾기	③ 보고서로 답 쓰기	④ 답
KURE-v2로 질문을 벡터로 바꿈	**kg_community_embedding** 가까운 보고서 상위 5개	**LLM이 보고서만 근거로** 없는 내용은 없다고 씀	**정답 요점 0 / 7** 상위 5에 있던 요점 4 / 7

Q23으로 찾은 상위 보고서

1. 광고 알림 과다 수신에 대한 고객 불만 및 상담...	consult_log
2. 민원 처리 경과 부재와 대기 사유 불명확에 대한...	consult_log
3. 카드 중복 문제에 대한 다채널 상담 및 제안 흐름	consult_log
4. 생활비 절약을 위한 구매 분류 및 알림 관리 상담	consult_log
5. 연회비 대비 가치에 대한 고객 불만 및 상담 흐름	consult_log

거시 질문 3개 결과 (정답 요점 수)

질문	보고서 전체	상위 5	답
Q23 고객군별 불만 주제	6 / 7	4 / 7	0 / 7
Q24 받아들여진 제안의 공통점	4 / 4	4 / 4	0 / 4
Q25 불만별 약관 조항과 혜택	2 / 7	0 / 7	0 / 7

찾기는 되지만 답이 약함

Q23: 불만 주제 6개가 보고서 전체에 모두 있고 상위 5개에 4개가 있으나, 그래프에 고객군 정보가 없어 LLM이 「보고서에 없음」으로 답함. Q25: 묶음 78개가 모두 한 문서 종류 안에서만 생기고 약관 보고서에 조항 번호가 없어 조항을 잇지 못함

무단전재 및 배포 금지