검색 갈래 ② 키워드 분석

파이썬에서 Kiwi로 낱말을 잘라 넣고, BM25 점수는 검색 엔진이 검색할 때 계산함



벡터DB 인덱싱(1-a)의 BM25 색인과 다른 점

	벡터DB 인덱싱 (bm25s)	검색 엔진 (1-b)
점수 계산	색인 때 점수표를 미리 만들어 저장	**검색할 때 역색인 통계로 계산**
갱신	하나만 바뀌어도 점수표를 다시 만듦 (항상 전체 재색인)	**바뀐 문서만 지우고 넣음 (증분 색인)**
전체 재색인	임시 폴더에서 만든 뒤 폴더 교체	**새 세대 인덱스를 채운 뒤 별칭 전환**

nori 대신 Kiwi를 쓰는 이유

1. 1-a의 토큰화 규칙과 사전을 그대로 씀
2. 검색 엔진에 형태소 플러그인을 깔지 않음
3. **대신 질문도 반드시 같은 토크나이저로 잘라야 함**

※ 점수 계산: 낱말마다 청크 안 빈도, 전체 청크 중 희소성, 청크 길이 보정을 합쳐 계산 (k1은 빈도, b는 길이 보정의 세기)

무단전재 및 배포 금지

카드명 사전과 별칭 사전은 한 쌍

카드명 사전만 넣으면 줄여 부른 카드명 질문이 문서의 카드명 낱말과 겹치지 않음

문서 한빛 가족돌봄 카드로 30,000원 이상 결제하면 KB-PAY 할인을 받습니다.

질문 **가족돌봄 카드 할인 조건이 뭐예요?**

사전 없음

문서 — 한빛 | **가족** | **돌봄** | **가족돌봄**

질문 — **가족** | **돌봄** | **가족돌봄**

겹치지만 카드 구분이 약함
'한빛'은 카드 64종 모두에,
'가족'은 한빛 가족통신에도 나옴

카드명 사전만

문서 — 한빛가족돌봄

질문 — 가족 | 돌봄 | 가족돌봄

카드명이 하나도 안 겹침
줄여 부르면 그 카드를 못 찾음

카드명 사전 + 별칭

문서 — **한빛가족돌봄**

질문 — **한빛가족돌봄** ← 별칭이 바꿈

그 카드 한 단어로 정확히 겹침
줄여 불러도 정식 카드명으로 찾음

파란 칩이 문서와 질문에서 겹친 낱말. 카드, 할인 같은 다른 낱말은 세 경우 모두 겹침

별칭 사전 만드는 법

사전이나 별칭이 바뀌면 문서 낱말도 바뀜 → 새 세대로 BM25 필드를 다시 만듦 (벡터는 재사용)

정식 카드명 64개
예) 한빛 가족돌봄

→

규칙으로 자동 생성
'한빛', '카드'를 떼고
3글자 이상만

→

별칭 189개
가족돌봄 → 한빛가족돌봄

→

일반 명사 자동 제외 3개
대중교통, 장보기, 출퇴근

→

사람 검수
추가 목록과 제외 목록

무단전재 및 배포 금지