오케스트레이터 ① 세대 ID 발급, ② 공통 단계

실행마다 세대 ID를 정하고, 원문을 개인정보 처리된 청크 파일 하나로 만들어 두 서브 워크플로우에 넘김

① 세대 ID 발급과 사전 검사

세대 ID 모양

gen-	birthfix-20261018b	-efeb65bd
접두어	실행 이름	실행 이름 해시 8자리

같은 실행 이름 = 같은 세대 ID
중단돼도 같은 세대로 이어서 만듦

두 서브 워크플로우의 공통 열쇠
card_chunks-gen-X, Neo4j gen-X

사전 검사: 할 일이 있는지 먼저 확인

원천 지문 수집
파일 SHA-256

→ **활성 세대 기록과 비교**
원천, 처리 정책, 문서 프로필, 토큰화, 임베딩 설정

→ **모두 같음**
실행 종료 (할 일 없음)

→ **하나라도 다름**
② 공통 단계로

전체 재색인을 요청하면 사전 검사를 건너뛰고 ②로 감

② 공통 단계: 원문 → 청크 파일

원천 문서
약관과 혜택 PDF
상담 이력 TXT

→ **로드와 가명처리**
회원 정보를
가명 키로 바꿈

→ **정제**
표기 정리
메타데이터 검증

→ **청킹**
문서별 분할 정책
카드 경계, 머리말

prepared-chunks.json + SHA-256
개인정보 처리된 청크만 저장 → K1, S1이 함께 읽음

원문은 남기지 않음
가명처리 전 원문은 메모리에서만 다루고 처리된 청크만 저장

바뀌지 않은 문서는 재사용
원천 해시와 처리 정책이 같으면 이전 세대의 처리된 청크를 씀

실행 중 원천이 바뀌면 중단
지문이 달라지면 같은 실행으로 이어 가지 않음

chunk_id 만드는 법: 본문이 같으면 ID도 같음

D1_27223010abe31291	_112f1e4abea05436	_0000
문서 키	본문 해시 16자리	같은 본문 반복 번호

청크 한 건: chunk_id, text, index_text(머리말 포함), metadata(가명 키 포함), text_hash, token_count

무단전재 및 배포 금지