검색 갈래 ③ 검색 엔진에 쓰기

문서 하나를 통째로 지우고 다시 넣어, 고친 문서의 옛 청크가 남지 않게 함

고친 문서 1 2 3 4 5 6 7 8 9 10 → **1′** 2 3 4 5 6 7 8 9

고치기 전 약관 문서 청크 10개

1번 본문 수정(ID 바뀜)
10번 삭제

고친 뒤 9개

청크 단위로 교체하는 방식 (chunk_id 기준)

chunk_id로 덮어쓴 뒤 인덱스에 남은 청크

옛1 | 1′ | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10

11개 남음
옛 1번과 빠진 10번(고아)이 검색에 섞여 나옴

문서 단위로 교체하는 방식 (doc_id 기준)

doc_id가 같은 청크 10개 지움 → **새 청크 9개 넣음**

1′ | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9

9개만 남음
고친 내용만 검색되고 고아 청크 없음

검색 엔진에 넣는 한 건 = 청크 하나

_id = chunk_id 같은 청크는 덮어씀	**doc_id** 지울 때 쓰는 원천 문서 키	**text_hash** 벡터 재사용 판단	**text** 보여 주기용, 색인 안 함	**text_tokens** 토큰화된 낱말	**embedding** 색인용 본문을 벡터화	**메타데이터** 카드명, 회원 키 등 필터

doc_id 만드는 법

D1_27223010abe31291 (문서 키) + **_112f1e4abea05436** (본문 해시) + **_0000** (청크 순번) → **chunk_id의 앞 칸만 남기면 doc_id.**
본문이 바뀌어도 문서 키는 그대로

무단전재 및 배포 금지

③ 검색 엔진에 쓰기 코드

문서별로 묶고, 옛 청크를 지우고, 새 청크를 한꺼번에 넣은 뒤 바로 보이게 함

search_branch.py 발췌 (타입 표기와 설명 주석은 줄임)

```
def step3_write_documents(client, index, documents):
    # ① 문서(doc_id)별로 묶음
    grouped = {}
    for document in documents:
        grouped.setdefault(document["doc_id"], []).append(document)
    # ② 문서마다 옛 청크를 통째로 지움
    deleted = 0
    for doc_id in grouped:
        response = client.delete_by_query(
            index=index,
            body={"query": {"term": {"doc_id": doc_id}}},
            refresh=True, conflicts="proceed")
        deleted += response.get("deleted", 0)
    # ③ 새 청크를 한꺼번에 넣음 (_id = chunk_id)
    actions = [{"_index": index, "_id": d["chunk_id"], "_source": d}
               for docs in grouped.values() for d in docs]
    helpers.bulk(client, actions, max_retries=3)
    # ④ 바로 검색되게 반영
    client.indices.refresh(index=index)
    return WriteReport(deleted, len(actions), tuple(grouped))
```

1 문서별로 묶음
여러 문서가 한꺼번에 들어와도 문서마다 따로 지움

2 옛 청크 지우기
term doc_id로 그 문서 청크를 모두 지움. refresh=True라 바로 반영되고, conflicts="proceed"는 충돌이 나도 멈추지 않음

3 한꺼번에 넣기
_id를 chunk_id로 고정해 같은 입력을 두 번 넣어도 건수가 그대로임. 일부가 실패하면 BulkIndexError

4 반영
넣은 청크가 다음 검색부터 보임

시험 결과: 옛 청크 9개 지움 → 10개 넣음, 고아 0개

운영 중인 인덱스에 바로 쓰면 ②와 ③ 사이에 그 문서가 잠깐 안 보임.
그래서 전체 재색인은 새 세대에 쓰고 검색이 보는 이름표만 바꿈

벡터DB 인덱싱의 활성 세대 파일
active_generation.json 교체
리트리버가 새 세대를 다시 읽어 올림

검색엔진 별칭
card_chunks를 새 인덱스로 옮김
엔진 안 이름표라 모든 검색에 바로 적용

무단전재 및 배포 금지

벡터 색인과 키워드 색인을 한 번에 구축

검색 엔진 인덱스 하나가 벡터 검색과 키워드 검색을 모두 맡아, 청크 한 건에 담아 한 번에 넣음



항목	벡터DB 인덱싱	검색 엔진
저장소	벡터는 Chroma, 키워드는 bm25s 파일 (두 군데)	검색 엔진 인덱스 한 군데
구축 순서	벡터를 Chroma에 먼저 넣고, BM25 점수표 파일을 따로 만듦	bulk 한 번에 둘 다
어긋나지 않게	둘 다 만든 뒤 활성 세대 파일 하나로 함께 게시	같은 한 건에 들어 있어 어긋날 수 없음
지우기	저장소마다 따로 처리	delete_by_query 한 번에 둘 다

벡터DB 인덱싱은 따로 만들고 마지막에 함께 바꾸고, 검색 엔진은 처음부터 함께 넣음

무단전재 및 배포 금지